

Sera Tarımında Pekıştirmeli Öğrenme

Şanlıurfa koşullarında PPO ile domates serasının iklim, sulama ve gübre kontrolü

Burak Kılıcı · 230202111

Doç. Dr. Alpaslan Burak İNNER

Kocaeli Üniversitesi · Bilgisayar Mühendisliği

Ekim 2026

SONUÇ ÖNDEN

Üç sayıda proje

4.30×

orijinal kural tabanlı kontrolcüye
göre verim

1.02×

900 kombinasyonla ayarlanmış kurala
göre verim

100/100

PPO'nun önde olduğu eşleştirilmiş
karşılaştırma (5 seed × 20 senaryo)

PPO, kural bilgisi olmadan doğru çalışma noktasını buluyor ve gübreyi sezona göre zamanlıyor. Ama bu ortamda iyi ayarlanmış basit bir kural onun performansının %98'ine ulaşıyor.

PROBLEM

Sıcak ve kurak bir sezonda sera yönetimi

12 → 32 °C

Dış sıcaklığın Mart'tan Temmuz'a mevsimsel trendi (günlük gürültü $\sigma = 1.5$ °C)

35 °C

Bu iç sıcaklığın üstünde domates büyümesi durur (sıcaklık stres faktörü $f_T = 0$)

%55 → %30

Dış hava nemi yazı doğru düşer; transpirasyon ve sulama ihtiyacı artar

120 gün

Bir yetiştirme sezonu = bir episode; ajan her gün dört kararı birlikte verir

Hedef: sezon sonunda en yüksek verim, en az su, enerji ve gübreyle. Hava sentetik, Şanlıurfa benzeri bir trendle üretiliyor (config.yaml → environment.weather).

NEDEN PEKİŞTİRMELİ ÖĞRENME?

Dört soru, dürüst cevaplar

Soru	Bu projede	Cevap
Eylem gelecekteki durumu etkiliyor mu?	Sulama ve gübre toprakta birikir; yarının su ve azotunu belirler	Evet
Ödül gecikmeli mi?	Toplam ödülün ~%24'ü sezon sonundaki hasat bonusundan gelir; gübrenin etkisi haftalar sonra görülür	Kısmen
Dinamik bilinmiyor mu, uzay büyük mü?	13 sürekli durum, 4 sürekli eylem, stokastik geçiş; tablo veya DP ile çözülemez	Evet
Basit bir kural aynı sonucu daha ucuza verir mi?	Validation'da ayarlanan oransal kural, test senaryolarında PPO'nun %98'ine ulaşıyor	Büyük ölçüde evet

Sonuç: problem RL ile çözülebiliyor ama RL'i zorunlu kılmıyor. PPO'nun katkısı çalışma noktasını kendi bulması ve gübreyi sezona göre zamanlaması.

Sıfırdan yazılmış sera simülasyonu: üç alt model

İklim

$$dT/dt \propto Q_{\text{güneş}} + Q_{\text{ısıtma}} - Q_{\text{hav}} - Q_{\text{kayıp}}$$

İç sıcaklık, nem ve CO₂; termal kütle yüzünden sıcaklık dengeye günlük %60 yaklaşır

Toprak, su, azot

$$\Delta W = \text{sulama} - ET - \text{drenaj}$$

Kova modeli, Hargreaves
evapotranspirasyon, bitki azot alımı ve drenajla yıkanma

Bitki

$$\Delta B = RUE \cdot I_{\text{PAR}} \cdot f(T) \cdot g(W) \cdot h(N)$$

Beer yasasıyla ışık yakalama, derece-gün ile gelişme; DVS = 2 olunca hasat

Ayarlanabilir her sayı (69 ortam parametresi, ödül ağırlıkları, hiperparametreler) config.yaml'da. Kodda yalnızca birim dönüşümleri ve formül sabitleri kaldı.

Durum ve eylem uzayı

Durum: 13 sürekli değişken

İç iklim

T_iç

H_iç

CO₂

Toprak

W_toprak

N_toprak

T_toprak

Bitki

LAI

B

DVS

Dış hava ve zaman

T_dış

H_dış

I_rad

gün/120

Eylem: 4 sürekli karar

Eylem	Fiziksel aralık
Isıtma	0–200 W/m ²
Havalandırma	0–%100 açıklık
Sulama	0–10 mm/gün
Gübre	0–5 kg N/ha/gün

Ağ $[-1, 1]$ üretir, ortam $[0, 1]$ orana çevirir. Episode 120 günde ya da $DVS \geq 2.0$ olunca biter; $\gamma = 0.99$.

ÖDÜL FONKSİYONU

Formül ve kodda karşılığı

Terim	Formül (ağırlık)	greenhouse_env.py
Büyüme ödülü	$+ w_y \cdot \Delta B$ (0.10)	satır 451
Sulama maliyeti	$- w_w \cdot a_{\text{sulama}}$ (0.015)	satır 452
Enerji maliyeti	$- w_e \cdot a_{\text{ısıtma}}$ (0.020)	satır 453
Gübre maliyeti	$- w_f \cdot a_{\text{gübre}}$ (0.020)	satır 454
Stres cezası	$- w_s \cdot (3 - f_T - g_W - h_N)$ (0.05)	satır 456
Nem cezası	$- w_h \cdot \max(0, H_{\text{iç}} - 0.85)$ (0.03)	satır 458
Hasat bonusu (son gün)	$+ w_{\text{verim}} \cdot \text{verim}$ (5.0)	satır 468

Günlük toplam 460. satırda. Ağırlıklar config.yaml $\rightarrow$ reward_weights. Satır numaraları bu sürüme aittir.

STOKASTIKLIK

Geçiş fonksiyonunun kendisi gürültülü

Hava (her episode)

```
weather_noise_T = 1.5  
weather_noise_I = 2.0  
weather_noise_H = 0.05  
WeatherGenerator.generate_season()
```

İklim geçişi (her gün)

```
climate_noise_T = 0.5  
climate_noise_H = 0.03  
climate_noise_CO2 = 5.0  
_climate_step()
```

Biyoloji (her gün)

```
biological_noise = 0.05  
_plant_step(): büyüme oranına  
~%5 varyans
```

Kanıt: config.yaml → environment.stochasticity altındaki gürültüler sıfırlanınca aynı seed ve aynı eylem dizisi farklı sonuç verir. Rastgelelik numpy.random.default_rng ile.

ALGORITMA

PyTorch ile sıfırdan PPO

Nasıl çalışıyor?

- On-policy: 2048 adım toplanır, 10 epoch kullanılır, sonra atılır; replay buffer yok
- Aktör $13 \rightarrow 128 \rightarrow 128 \rightarrow 4$ (Tanh), kritik ayrı ağ
- Diagonal Gauss politika; $\log \sigma$ öğrenilen, durumdan bağımsız parametre
- GAE ile avantaj, kırpılmış vekil amaç, gradyan normu kırpma
- Gözlemler Welford koşan ortalamasıyla normalize

Hiperparametreler

Parametre	Değer
Toplam adım	500 000
Rollout / epoch / minibatch	2048 / 10 / 64
Öğrenme oranı	0.0003
γ / λ (GAE)	0.99 / 0.95
clip ϵ	0.20
vf_coef / ent_coef	0.5 / 0.0
Gizli katman	128×2

DENEY DÜZENİ

Hangi senaryo ne için kullanıldı?


Amaç	Seedler	Kullanım
Eğitim	0, 1, 2, 3, 42	Her biri 500 000 adım, aynı kodla, aynı günde
Eval eğrisi (validation)	3000–3004	Her 10 güncellemede deterministik test
Kural araması (validation)	3000–3009	900 eşik kombinasyonundan seçim
Final test	2000–2019	Yalnızca son değerlendirme; eğitimde ve aramada hiç görülmedi
Duman testi	1000–1004	Ortamin anlamlı sinyal ürettiğinin kontrolü
Davranış analizi	2026	Trajektori karşılaştırması ve politika sondajı

Tüm grafikler ve tablolar sonuçlar/loglar altındaki ham CSV loglarından üretildi; plot_results.py grafikleri yalnızca bu dosyalardan çiziyor.

GRAFIK 1 • ÖĞRENME EĞRISI

Beş seed aynı yoldan öğreniyor

Grafik 1 — Öğrenme eğrisi (eğitim) | 5 seed, ort. $\pm$ std, hareketli ortalama w = 20 episode



132. episode'da orijinal kural aşıyor, plato 127.8; son noktada seedler arası std yalnızca 1.13.

Hızlı, kararlı ve tohumdan bağımsız

GÖZLEM

Ortalama getiri 86. episode'da max-out'u, 132. episode'da orijinal kuralı aşıyor; son 100 noktada 127.8 platosuna oturuyor.

KARŞILAŞTIRMA

Beş seed neredeyse üst üste; platonun %95'ine 1379. episode'da ulaşıyor, son noktada seedler arası std yalnızca 1.13.

AÇIKLAMA

Hasat bonusu baskın yoğun ödül güçlü sinyal veriyor; GAE varyansı düşürüyor, clip adımları küçük tutuyor, çöküş yok.


SONUÇ

PPO bu ortamda kararlı öğreniyor; yaklaşık 1400 episode'dan (~165 bin adım) sonra ek eğitimin getirisi küçük.

GRAFIK 2 • TEST (EVAL) EĞRISI

Gürültüsüz politika her noktada önde

Grafik 2 — Test (eval) eğrisi | her 10 güncellemede 5 validation senaryosu, 5 seed ort. $\pm$ std



Deterministik test ile eğitim arasındaki fark, keşif gürültüsü azaldıkça 23.5 puandan 2.3 puana iniyor.

Keşiften sömürüye geçiş

GÖZLEM

Deterministik test her ölçümde eğitimin üstünde; fark 20 480. adımda 23.5 puan, son ölçümde 2.3 puan.

AÇIKLAMA

Fark keşif gürültüsünden: σ eğitim boyunca ≈ 0.60 'tan ≈ 0.17 'ye iniyor (Grafik 3), stokastik politika ortalamasına yaklaşıyor.

KARŞILAŞTIRMA


Son ölçümde validation 130.8, eğitim 128.4; görülmemiş 20 test senaryosunda seed ortalamaları 129.2 ± 0.7 .

SONUÇ

Eğitim eğrisi gerçek performansı düşük gösteriyor; validation ve test aynı seviyede, senaryolar ezberlenmemiş.

GRAFIK 3 • LOSS EĞRİLERİ

Kayıplar keşfin nasıl azaldığını gösteriyor



Ölçüt	İlk	Son
Entropi (nat)	3.64	-1.48
Yaklaşık KL	0.019	0.025
Clip oranı	0.26	0.29
Değer kaybı	0.37	0.49
Policy kaybı	-0.016	-0.009

Değer kaybı 22 500. adımda 0.99 ile tepe yapıyor; ~391 bin adımdaki sıçrama tek bir seed'den (seed 3).

Yorum ve kayıpların nasıl okunacağı: sonraki iki slayt.

Iraksama değil, keşfin azaldığı bir yakınsama

GÖZLEM

Entropi 3.64'ten -1.48'e iniyor; KL 0.019 $\rightarrow$ 0.025, clip oranı 0.26 $\rightarrow$ 0.29; değer kaybı 0.99 tepeden 0.4-0.5 bandına iniyor.

KARŞILAŞTIRMA

Seedler çok yakın; tek sapma ~391 bin adımda seed 3'ün değer kaybı ve KL'sindeki kısa sıçrama, hemen toparlanıyor.

AÇIKLAMA

ent_coef = 0 σ 'yı frenlemiyor; σ küçüldükçe aynı ortalama kayması oranı ($\propto 1/\sigma$) daha çok değiştirir, KL ve clip yükselir.

SONUÇ

Bu bir iraksama değil; uzun eğitimlerde σ 'nın çökmesini önlemek için ent_coef > 0 ya da log σ alt sınırı denenmeli.

PPO kayıpları nasıl okunmalı?

POLICY KAYBI

Denetimli öğrenmedeki gibi 'düşen kayıp' değildir. Avantajlar normalize edildiği için hep sıfıra yakın kalır; büyüklüğü yakınsamayı değil, her güncellemenin vekil amacı ne kadar iyileştirdiğini gösterir.

DEĞER KAYBININ TEPESİ

İlk 20 bin adımda getiri -3'ten 60'ın üstüne çıkıyor; kritiğin tahmin etmesi gereken hedefler onun takip hızından hızlı kayıyor. Getiri oturunca kayıp da oturuyor.

NEDEN SIFIRA INMIYOR?

Ortam stokastik: aynı durumdan farklı getiriler gelebilir. Politika değiştikçe hedef değerler de değişir.


Öğrenmenin asıl kanıtı Grafik 1 ve 2'deki getiri. Kayıp eğrileri, eğitimin sağlıklı ilerlediğini ve keşfin nasıl azaldığını gösteren teşhis araçlarıdır.

GRAFIK 4 • HIPERPARAMETRE DUYARLILIĞI


Öğrenme oranı değil, clip belirleyici

Grafik 4 — Hiperparametre duyarlılığı | 150,000 adım, 5 seed, hareketli ortalama w = 20 episode

(a) Öğrenme oranı (clip_eps = 0.2)



(b) PPO clip_eps (lr = 0.0003)



lr'deki 10 kat değişim ~3 puan fark yaratıyor; clip_eps 0.1 ile 0.3 arasında ~15 puan. 150 bin adım, 5 seed.

Keşif ile sömürü arasındaki denge clip'te

GÖZLEM

Son 30 episode: lr 0.0001 / 0.0003 / 0.001 $\rightarrow$ 114.1 / 115.3 / 117.5;
clip 0.1 / 0.2 / 0.3 $\rightarrow$ 105.6 / 115.3 / 120.7.

KARŞILAŞTIRMA

lr 'de bantlar örtüşüyor, fark ~ 3 puan; clip'te 0.1 ile 0.3 arasında eğitim boyunca açık kalan ~ 15 puanlık fark var.

AÇIKLAMA


Politika değişimini clip sınırlıyor: oran $[1-\epsilon, 1+\epsilon]$ dışına çıkınca gradyan sıfırlanır; yüksek lr sınıra yalnızca daha çabuk varır.

SONUÇ

lr 'ye sağlam, clip'e duyarlı; 0.3 bu bütçede daha hızlı ama en dağınık (± 5.5). 150 bin adım yakınsamamış bir ara nokta.

GRAFIK 5 • BASELINE KARŞILAŞTIRMASI

Görülmemiş 20 senaryoda final test



Orijinal kurala 4.30x, ayarlı kurala 1.02x verim; eşleştirilmiş karşılaştırmada PPO 100'ün 100'ünde önde.

Tutarlı ama küçük bir üstünlük

GÖZLEM

PPO 129.2 ± 3.6 ödül ve 6.23 t/ha alıyor; ayarlı kural 126.4 / 6.11, orijinal kural 23.8 / 1.45, max-out 10.9 / 1.07.

KARŞILAŞTIRMA

Orijinal kurala göre $4.30\times$, ayarlıya göre $1.02\times$ verim; eşleştirilmiş fark 2.83 ± 0.31 , her seed 20 senaryonun 20'sinde önde.

AÇIKLAMA

Orijinal kural toprağı 120 günün 120'sinde su stresinde tutuyor; kural ayarlanınca fark kapanıyor, kalanı zamanlamadan geliyor.

SONUÇ

Kazanç tutarlı ama küçük; bu ortamın en iyi politikası sabit eşiklere yakın, bu yüzden RL'in avantajı sınırlı.

Kural tabanlı kontrolcüyü de ayarlamak

Yöntem

- Beş eşik: sıcaklık hedefi ve bandı, toprak suyu hedefi ve bandı, azot hedefi
- 900 kombinasyon × 10 validation senaryosu
- Seçim ölçütü PPO'nunkiyle aynı: ortalama ödül
- Test senaryoları aramada hiç kullanılmadı
- Sınıra düşen eşiklerde ızgara genişletildi

Seçilen: T 14 °C, bant 10 °C, W 0.35, W bandı 0.03, N 350 kg/ha

Politika (20 test senaryosu)	Ödül	Verim
Orijinal kural	23.81	1.45
Ayarlı kural	126.35	6.11
PPO, 5 seed	129.18	6.23

2.83 ± 0.31

eşleştirilmiş ödül farkı

100/100

PPO'nun önde olduğu karşılaştırma


FARK NEREDEN GELİYOR?

Ödül bileşenlerine ayrıştırma

Ödül kalemi (20 test senaryosu ort.)	Ayarlı kural	PPO	PPO'nun kazancı	Pay
Günlük büyüme ödülü	101.64	103.55	+1.91	%68
Hasat bonusu	30.55	31.13	+0.57	%20
Gübre maliyeti	-2.16	-1.64	+0.52	%18
Stres cezası	-3.11	-3.09	+0.02	%1
Su ve enerji maliyeti	-0.57	-0.77	-0.20	-%7
Toplam	126.35	129.18	+2.83	%100

Kalemlerin toplamı final değerlendirmedeki farkla birebir tutuyor. Kaynak: sonuclar/politika_davranis_ozet.csv

Gübreinin sezona göre zamanlanması



%11 **%26** **%43**

PPO

ayarlı kural

orijinal


Gübreinin sezonun son üçte birinde verilen oranı (20 test senaryosu, PPO 5 seed ort.)

PPO azotu ~40. günde zirveye çıkarıp hasada doğru düşürüyor; ayarlı kural 350 hedefine bakmaya devam ediyor.

Sonuç: %24 daha az gübreyle (411 / 541 kg N/ha) daha fazla verim.

Sezonu bilmeyen sabit bir eşik bunu yapısal olarak yapamaz.

Gübre kararı sıcaklığa ve LAI'ye birlikte bağlı



Gerçek bir sezon ortası durumu (84. gün) alındı; yalnızca iç sıcaklık ve LAI değiştirildi.

GÜBRE

22 °C'de $\approx 0.59 \rightarrow 0.72$, 32 °C'de $\approx 0.33 \rightarrow 0.42$. Sıcakta büyüme zaten yavaş ($f_T \approx 0.33$), fazla azotun getirisi düşük.

HAVALANDIRMA

Her koşulda neredeyse tam açık ($\approx 0.87-1.0$).

DÜZELTME

Eski sunumdaki 'yüksek LAI'de havalandırma %12' iddiası ölçümle desteklenmedi, çıkarıldı.

PPO'nun zayıf noktaları

Sezon sonu ısıtma

İç sıcaklık 35 °C'yi aşınca büyüme zaten sıfır; ajan orada anlamsız bir ısıtma yapıyor. Enerji maliyetinin (0.13) kaynağı bu.

Keşfin çökmesi

Entropi eğitim boyunca durmadan düşüyor ($\sigma \approx 0.17$); ent_coef = 0 bunu frenlemiyor.

Kaynak kullanımı

Orijinal kurala göre 8.3× gübre ve 2.1× su; ödül nitrat yıkanmasını cezalandırmıyor, ajan teşviklere uyuyor.

Geçici kararsızlık

Seed 3'te ~391 bin adımda değer kaybı ve KL sıçraması; getiri kısa süre düşüp toparlanıyor.

Neyi göstermedik, sırada ne var?

Sınırlamalar

- Hava sentetik, sera modeli sadeleştirilmiş
- Ortamın en iyi politikası sabit eşiklere yakın; RL'in avantajı bu yüzden küçük
- Rakip yalnızca oransal (P) kontrolcü; PI ve MPC denenmedi
- Hiperparametre taraması 150 bin adımda, yakınsama öncesi

Gelecek çalışma

- PI ve MPC kontrolcülerle karşılaştırma
- Gerçek MGM hava verisiyle eğitim ve sim-to-real analizi
- $\text{ent_coef} > 0$ veya $\log \sigma$ alt sınırı; ödüle nitrat yıkanması cezası
- Zamanlamanın gerçekten önemli olduğu kararlar: mantar tesisi projesi

SONUÇ

Ne öğrendik?

PPO, kural bilgisi olmadan doğru çalışma noktasını buldu: toprak tarla kapasitesinde, azot sezon başında yüksek, gübre sona doğru kesiliyor.

Orijinal kurala göre $4.30\times$, adilce ayarlanmış kurala göre $1.02\times$ verim; 5 seed $\times$ 20 senaryoda 100 karşılaştırmanın 100'ünde önde.

Bu ortamda RL'in avantajı küçük. Asıl ders: iddiayı ölçmek, rakibi adil kurmak ve RL'in değerini zamanlamanın önemli olduğu problemlerde aramak.